

UNIVERSIDAD VERACRUZANA

Facultad de Estadística e Informática

Licenciatura en Ingeniería en Ciencia de Datos

APLICACIÓN DE LA METODOLOGÍA TDSP

Análisis del rendimiento en exámenes de estudiantes

Metodología de la Investigación

Docente: Lorena López Lozada

Integrantes

Alonso Limon Zurizaday

Osorio Morales Jeane Anady

Llanos Ramon Ruben

02 de octubre de 2026

Contenido

1. Comprensión Empresarial	4
2. Adquisición y Comprensión de Datos	4
3. Modelado	6
4. Despliegue.....	6
5. Aceptación del Cliente	7

Nuestro análisis se basa en el conjunto de datos Students Performance, que contiene 1,000 registros de estudiantes, utilizando la metodología TDSP para organizar el proyecto desde la adquisición y comprensión de los datos hasta el modelado, despliegue y aceptación de los resultados. El objetivo es analizar qué factores sociodemográficos y de preparación académica se relacionan con el rendimiento promedio en los exámenes de matemáticas, lectura y escritura.

Para organizar el proyecto de análisis del rendimiento en exámenes de estudiantes bajo la metodología Team Data Science Process (TDSP), se distribuyeron las responsabilidades entre los tres integrantes del equipo, considerando los ocho roles clave en ciencia de datos: Científico de Datos, Ingeniero de Datos, Analista de Datos, Ingeniero de Aprendizaje Automático, Propietario de Producto, Experto en Procesos, Gestor de Proyecto y Jefe de Equipo.

• **Alonso Limon Zurizaday — Gestora de Proyecto, Propietaria de Producto y Jefa de Equipo:** Responsable de coordinar y supervisar las actividades del equipo durante el desarrollo del proyecto. Como Gestora de Proyecto, se encarga de organizar las actividades, establecer tiempos de trabajo, distribuir responsabilidades y dar seguimiento al cumplimiento de las diferentes etapas de TDSP. Como Propietaria de producto, define el objetivo del proyecto, delimita el problema de investigación, establece los criterios de éxito y verifica que los resultados obtenidos respondan al propósito planteado. Como Jefa de Equipo, coordina la colaboración entre los integrantes, facilita la comunicación y supervisa que cada integrante cumpla con las actividades asignadas. También integra los resultados, conclusiones y recomendaciones en el reporte final.

• **Osorio Morales Jeane Anady — Científica de Datos, Analista de Datos e Ingeniera de Aprendizaje Automático:** Responsable del análisis de los datos y del desarrollo de los modelos predictivos para estudiar el rendimiento académico de los estudiantes. Como Analista de datos , realiza el análisis exploratorio, genera e interpreta las gráficas y analiza las relaciones entre las variables y el promedio general. Como Científica de datos, identifica patrones en los datos y utiliza los resultados del análisis para responder a los objetivos planteados. Como Ingeniera de aprendizaje automático , se encarga de ajustar y evaluar los modelos de Regresión Lineal y Random Forest, comparando su desempeño mediante las métricas MAE, RMSE y R^2 . Asimismo, analiza la importancia de las variables predictoras, interpreta los resultados de los modelos y señala sus principales limitaciones.

• **Ruben Llanos Ramon — Ingeniero de Datos y Experto en Procesos :** Responsable de la carga, revisión y preparación del conjunto de datos Students Performance utilizando Python. Como ingeniero de datos, verifica la calidad de los datos, identifica valores faltantes y registros duplicados, calcula el promedio general de las tres calificaciones y prepara las variables categóricas mediante codificación One Hot. También realiza la división de los datos en entrenamiento (80%) y prueba (20%), asegurando que las calificaciones individuales utilizadas para calcular el promedio general sean excluidas de los predictores para evitar la fuga de información. Como experto en procesos, verifica que las actividades de preparación, análisis y modelado se desarrollen de manera ordenada y de

acuerdo con las etapas establecidas en la metodología TDSP, apoyando en la documentación y seguimiento del proceso.

Para el desarrollo del proyecto se utilizó Python mediante Google Colab, entorno empleado para cargar y preparar el conjunto de datos, realizar el análisis exploratorio y generar las gráficas necesarias. Entre estas se encuentran las visualizaciones de la distribución del promedio general, la comparación del rendimiento académico según la realización de un curso de preparación y el análisis de la importancia de las variables predictoras. Asimismo, Google Colab fue utilizado para entrenar y evaluar los modelos de Regresión Lineal y Random Forest, permitiendo comparar su desempeño mediante las métricas seleccionadas e interpretar los resultados obtenidos.

La distribución de estos ocho roles permite cubrir las principales actividades involucradas en el proyecto: definición y gestión del objetivo, coordinación del equipo, preparación y calidad de los datos, análisis exploratorio, desarrollo de modelos de aprendizaje automático y seguimiento del proceso de trabajo. De esta manera, las responsabilidades de los tres integrantes se complementan y mantienen una organización coherente con la metodología TDSP.

1. Comprensión Empresarial

El ciclo de vida del Team Data Science Process (TDSP) inicia definiendo los objetivos del negocio y el alcance del problema analítico. En este proyecto, el objetivo central es identificar qué factores sociodemográficos y de preparación académica guardan relación con el rendimiento promedio de los estudiantes en los exámenes de matemáticas, lectura y escritura, utilizando un conjunto de datos estandarizado.

- **Objetivo analítico:** Construir modelos predictivos y analíticos para explicar la variabilidad en el promedio general del rendimiento de los estudiantes a partir de variables contextuales previas a la evaluación.
- **Criterios de éxito:** Lograr métricas de error interpretables y analizar la importancia relativa de las variables categóricas (como el tipo de alimentación y los cursos de preparación) para ofrecer insumos informativos de valor institucional.

2. Adquisición y Comprensión de Datos

La fase de adquisición recopila y explora la fuente de datos. El conjunto utilizado Students Performance contiene 1,000 registros y 8 variables originales. Tras la revisión automatizada en Python, se confirmó que no existen valores faltantes ni registros duplicados, por lo que no se requirieron procesos de imputación complejos.

- **Variables originales:** Género, grupo étnico, nivel educativo de los padres, tipo de almuerzo, curso de preparación, y calificaciones en matemáticas, lectura y escritura.

- Variable Objetivo creada: Se calculó el promedio aritmético de las tres calificaciones para consolidar el rendimiento general en una escala continua de 0 a 100.




Figura 1. Distribución del promedio general de calificaciones de los estudiantes.

Adicionalmente, se analizaron de forma descriptiva las variables categóricas clave, destacando el impacto del curso de preparación sobre el promedio general:




Figura 2. Comparación del promedio general según la realización de un curso de preparación.

3. Modelado

Siguiendo las directrices de TDSP, se estructuró un pipeline de modelado predictivo dividiendo los datos en un conjunto de entrenamiento (80%) y un conjunto de prueba (20%) con una semilla reproducible de 42.

Para evitar la fuga de información, se excluyeron deliberadamente los puntajes individuales (math score, reading score, writing score) como variables predictoras, ya que el objetivo (average_score) se deriva directamente de ellos. Las variables categóricas se transformaron mediante codificación One-Hot.

Se evaluaron dos algoritmos de aprendizaje automático:

1. Regresión Lineal: Modelo paramétrico base de referencia.
2. Random Forest Regressor: Modelo de ensamblaje no lineal avanzado.

Resultados comparativos en el conjunto de prueba:

Modelo	Error Absoluto Medio	Raíz del error cuadrático medio	Coefficiente de determinación
Regresion lineal	10.49	13.40	0.162
Random forest	11.48	14.77	-0.019

La Regresión Lineal demostró un desempeño superior al obtener un menor error y un coeficiente de determinación positivo ($R^2 = 0.162$), mientras que el modelo de bosques aleatorios mostró sobreajuste en este volumen de datos categóricos reducidos.

4. Despliegue

En el marco de TDSP, la fase de despliegue evalúa la interpretabilidad de los inductores de valor para determinar cómo se consumirán los resultados. Utilizando la estructura de los modelos entrenados, se identificaron los factores con mayor peso predictivo sobre el rendimiento académico:




Figura 3. Importancia relativa de las variables predictoras analizadas.

- Factores más influenciadores: El tipo de almuerzo y la ausencia o presencia de cursos de preparación funcionan como los predictores más determinantes dentro de las características analizadas.
- Limitaciones técnicas: El valor bajo de R^2 indica que las variables sociodemográficas disponibles explican únicamente una fracción menor (aprox. 16.2%) de la variabilidad total del rendimiento, lo que advierte que el modelo no debe emplearse para diagnósticos individuales automatizados.

5. Aceptación del Cliente

La aplicación del ciclo TDSP permitió estructurar el proyecto desde la comprensión de las necesidades analíticas hasta la validación rigurosa de los algoritmos predictivos, garantizando la reproducibilidad del código en Python y el control de sesgos como la fuga de datos. Si bien se identificaron asociaciones estadísticas claras como la ventaja en el rendimiento de aquellos estudiantes con almuerzo estándar o cursos de preparación concluidos, el poder predictivo global de las variables sociodemográficas es limitado.

Para fases posteriores de despliegue operativo en una institución educativa, se recomienda incorporar métricas de seguimiento continuo, horas de estudio autónomo, asistencia y contexto socioeconómico ampliado para robustecer la capacidad explicativa de los modelos.

Referencias

Google. (s. f.). *Google Colab* [Entorno de desarrollo basado en Jupyter]. Google Research.
[Google Colab](#)

SAS Institute Inc. (s. f.). Data mining and SEMMA. SAS Support.
<https://support.sas.com/documentation/cdl/en/emcs/66392/HTML/default/n0pejm83csbja4n1xueveo2uoujy.htm>

Seshapanpu, J. (s. f.). Students Performance in Exams [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.